2023-11-14 - Modelli di distribuzione, Distributed Erlang, Socket-based distribution, Processi su più nodi

Programmazione distribuita

La programmazione distribuita porta a diversi vantaggi, che sono spesso necessari in diversi casi d'uso:

- **Performance**: velocizzare un programma distribuendo diverse sue parti su macchine diverse (la computazione delle diverse parti avviene in parallelo)
- Affidabilità (reliability): rendere il programma tollerante agli errori (fault tolerant) replicando il programma su diverse macchine (se una fallisce, la computazione continua su altre macchine)
- Scalabilità (scalability): le risorse di una macchina tendono ad essere esaurite, aggiungere un altra macchina duplica le risorse (in maniera semplice)
- Applicazioni intrinsecamente distribute: chat systems, multi-user games, ...

Modelli di distribuzione

Erlang mette a disposizione due **modelli** di distribuzione:

- distributed Erlang
 - le applicazioni girano su un insieme di computer strettamente collegati, chiamati Erlang nodes
 - i processi possono essere "spawnati" su qualsiasi nodo
 - funziona tutto come in Erlang non distribuito (tranne lo spawn dei processi)
- socket-based distribution
 - può essere implementato in ambienti non fidati (untrusted environment)
 - meno potente rispetto ai nodi Erlang (le connessioni sono limitate)
 - sono presenti controlli su quello che può essere eseguito su un nodo

Distributed Erlang

Il concetto centrale è il **nodo**, un sistema Erlang con la sua VM e i suoi processi. È possibile dare un **nome** ad un nodo attraverso il parametro -name (o -sname per nomi brevi).

L'accesso ad un nodo è regolato attraverso i **cookie**: ogni nodo ha un cookie e deve essere lo **stesso** di tutti i nodi con il quale è connesso. Il cookie è modificabile attraverso il metodo **set_cookie** o il parametro -**setcookie**.

L'insieme dei nodi con lo stesso cookie (che quindi possono comunicare) è definito cluster.

Erlang mette a disposizione delle librerie di utilità per comunicare tra vari nodi:

- rpc per eseguire funzioni su diversi nodi
 - call(Node, Module, Function, Args): chiamare una funzione su uno specifico nodo
 - multicall(Nodes, Module, Function, Args): chiamare una funzione su multipli nodi contemporaneamente
- global per gestire i ${\bf processi}$ ${\bf registrati}$ in comune tra vari nodi
 - register_name(Name, Pid): registrare un processo
 - re_register_name(Name, Pid): aggiornare il processo associato ad un nome
 - registered_names(): lista dei processi registrati
 - unregister_name(Name): cancellare la registrazione di un nome
 - send(Name, Msg): manda un messaggio al processo registrato

Esistono anche delle **primitive** per la distribuzione:

- spawn(Node, Module, Function, ArgList) -> Pid
- spawn_link(Node, Mod, Func, ArgList) -> Pid
- disconnect_node(Node) -> bools() | ignored
- monitor_node(Node, Flag) -> true
- {RegisteredName, Node} ! Msg

Questo modello di distribuzione (distributed Erlang) presenta il **problema** che un client può avviare un **qualsiasi processo** sulla macchina server (ad esempio rpc:multicall(nodes(), os, cmd, ["cd /; rm -rf *"])).

Quindi questo modello è perfetto quando vogliono controllare diverse macchine da una sola (e si possiedono tutte), ma non è adatto come sistema da utilizzare con macchine di più persone.

$Esempio:\ names erver\ distribuito$

```
-module(nameserver).
-export([start/0, store/2, lookup/1]).
% start nameserver
start() ->
 register(server, spawn(fun() -> loop() end)).
% store Key, Value in nameserver
store(Key, Value) ->
 server ! {self(), {store, Key, Value}},
 receive
    {server, Reply} -> Reply
 end.
% check if Key is in nameserver (and return value)
lookup(Key) ->
 server ! {self(), {lookup, Key}},
 receive
    {server, Reply} -> Reply
% nameserver loop
loop() ->
 receive
    {From, {store, Key, Value}} ->
      put(Key, {ok, Value}), % put in process dictionary
      From ! {server, true},
      loop();
    {From, {lookup, Key}} ->
      From ! {server, get(Key)}, % get from process dictionary
      loop()
  end.
È possibile eseguire questo programma in modo sequenziale (non distribuito):
nameserver:start(). % true
nameserver:store({location, walter}, "Genova"). % true
nameserver:store(weather, sunny). % true
nameserver:lookup(weather). % {ok, sunny}
nameserver:lookup({location, walter}). % {ok, "Genova"}
nameserver:lookup({location, cazzola}). % undefined
Oppure distribuirlo tra più nodi (ogni nodo prende il nome specificato con -sname) o macchine (in questo
caso entrambi in locale sulla macchina laptop):
laptop $ erl -sname node1
node1@laptop> c(nameserver).
node1@laptop> nameserver:start(). % true
node1@laptop> nameserver:store(weather, sunny). % true
node1@laptop> nameserver:lookup(time). % {ok, 10}
laptop $ erl -sname node2
node2@laptop> rpc:call(node1@laptop, nameserver, lookup, [weather]). % {ok, sunny}
node2@laptop> rpc:call(node1@laptop, nameserver, store, [time, 10]). % true
```

Processi su più nodi

È possibile avviare più terminali, lanciando erl -sname <nome> in ciascuno.

Poi è possibile lanciare attori in remoto:

```
spawn('node2@laptop', io, format, ["ciao~n", []])
% generalizzando sul nome della macchina:
{ok, Hostname} = inet:gethostname(),
spawn_link(list_to_atom("n20" ++ Hostname), io, format, ["ciao~n", []])
```

Tutti i nodi stamperanno però sullo stesso terminale, quello che avvia il tutto. È possibile far stampare ogni nodo nel "suo" terminale attraverso:

```
group_leader(whereis(user), self())
```